

# Clasificación

**Taller de Procesamiento de Señales**

# Agenda

- 1 Introducción al problema de clasificación
- 2 Regresión Logística Binaria
- 3 Regresión Logística Categórica
- 4 Linear Discriminant Analysis
- 5 K-Vecinos más cercanos
- 6 Support Vector Machines
- 7 Árboles de decisión

# Teoría de Clasificación

## Bases

**Objetivo:** Clasificar  $Y$  (con  $|\mathcal{Y}|$  finito) a partir del valor de  $X$ :  $\hat{Y} = \varphi(X)$

**Función costo:** Hard  $\rightarrow \ell(x, y) = \mathbb{1}\{y \neq \varphi(x)\}$

**Riesgo Esperado:** Probabilidad de error  $\rightarrow \mathbb{P}(Y \neq \varphi(X))$

# Teoría de Clasificación

## Bases

**Objetivo:** Clasificar  $Y$  (con  $|\mathcal{Y}|$  finito) a partir del valor de  $X$ :  $\hat{Y} = \varphi(X)$

**Función costo:** Hard  $\rightarrow \ell(x, y) = \mathbb{1}\{y \neq \varphi(x)\}$

**Riesgo Esperado:** Probabilidad de error  $\rightarrow \mathbb{P}(Y \neq \varphi(X))$

## Optimalidad

$$\mathbb{P}(Y \neq \varphi(X)) \geq 1 - \mathbb{E} \left[ \max_y P_{Y|X}(y|X) \right]$$

con igualdad si y solo si  $\varphi(x) = \arg \max_y P_{Y|X}(y|x)$ .

**Clasificador Bayesiano:**  $\varphi(x) = \arg \max_y P_{Y|X}(y|x)$

**Error Bayesiano:**  $1 - \mathbb{E} \left[ \max_y P_{Y|X}(y|X) \right]$

# Clasificador bayesiano

## Objetivo

Quiero buscar  $\varphi(\cdot)$  que minimice  $\mathbb{P}(Y \neq \varphi(X))$ . Es decir aprender el “clasificador bayesiano”:  $\varphi(x) = \arg \max_y P_{Y|X}(y|x)$ .

# Clasificador bayesiano

## Objetivo

Quiero buscar  $\varphi(\cdot)$  que minimice  $\mathbb{P}(Y \neq \varphi(X))$ . Es decir aprender el “clasificador bayesiano”:  $\varphi(x) = \arg \max_y P_{Y|X}(y|x)$ .

## Problemas numéricos

La propuesta de buscar  $\varphi(\cdot)$  que minimice el riesgo empírico:  $\frac{1}{n} \sum_{i=1}^n \mathbb{1}\{Y_i \neq \varphi(X_i)\}$  suele tener problemas numéricos (no derivable).

# Clasificador bayesiano

## Objetivo

Quiero buscar  $\varphi(\cdot)$  que minimice  $\mathbb{P}(Y \neq \varphi(X))$ . Es decir aprender el “clasificador bayesiano”:  $\varphi(x) = \arg \max_y P_{Y|X}(y|x)$ .

## Problemas numéricos

La propuesta de buscar  $\varphi(\cdot)$  que minimice el riesgo empírico:  $\frac{1}{n} \sum_{i=1}^n \mathbb{1}\{Y_i \neq \varphi(X_i)\}$  suele tener problemas numéricos (no derivable).

## Posible solución

El clasificador bayesiano se aprenderá en dos etapas:

- Aprender toda  $P_{Y|X}(y|x)$ .
- Quedarse con el máximo.

# Clasificadores extremos

## Clasificador bayesiano

El mejor clasificador (en términos de la probabilidad de error) es:

$$\mathbb{P}(Y \neq \varphi(X)) \geq 1 - \mathbb{E} \left[ \max_y P_{Y|X}(y|X) \right]$$

## Clasificador al azar para $k$ clases

Cualquier clasificador razonable debe ganarle a la decisión al azar:

$$\mathbb{P}(Y \neq \varphi(X)) \leq 1 - \frac{1}{k}$$

## Clasificador dummy

Otro clasificador muy precario (pero mejor que el azaroso) es elegir siempre la clase más probable. La probabilidad de error del dummy es:

$$\mathbb{P}(Y \neq \varphi(X)) \leq 1 - \max_y P_Y(y)$$



# Elementos de Teoría de Información

- $H(X) = \mathbb{E} [-\log P_X(X)]$  Entropía
- $h(X) = \mathbb{E} [-\log p_X(X)]$  Entropía diferencial
- $H(Y|X) = \mathbb{E} [-\log P_{Y|X}(Y|X)]$  Entropía condicional
- $h(Y|X) = \mathbb{E} [-\log p_{Y|X}(Y|X)]$  Entropía diferencial condicional
- $\text{KL}(p_X \| q_X) = \mathbb{E} \left[ \log \left( \frac{p_X(X)}{q_X(X)} \right) \right]$  Divergencia de Kullback Leibler
- $I(X; Y) = \text{KL}(p_{XY} \| p_X p_Y)$  Información Mutua

# Elementos de Teoría de Información

- $H(X) = \mathbb{E}[-\log P_X(X)]$  Entropía
- $h(X) = \mathbb{E}[-\log p_X(X)]$  Entropía diferencial
- $H(Y|X) = \mathbb{E}[-\log P_{Y|X}(Y|X)]$  Entropía condicional
- $h(Y|X) = \mathbb{E}[-\log p_{Y|X}(Y|X)]$  Entropía diferencial condicional
- $\text{KL}(p_X \| q_X) = \mathbb{E}\left[\log\left(\frac{p_X(X)}{q_X(X)}\right)\right]$  Divergencia de Kullback Leibler
- $I(X; Y) = \text{KL}(p_{XY} \| p_X p_Y)$  Información Mutua

## Teorema

$$\text{KL}(P \| Q) \geq 0$$

con igualdad si y solo si  $P(y) = Q(y)$  para todo  $y \in \mathcal{Y}$ .

(Hint:  $\log(x) \leq x - 1$ ).

# Divergencia de Kullback Leibler

## Propuesta inicial

Busco  $\hat{P}(y|x)$  que minimice:

$$\underbrace{\mathbb{E} \left[ KL \left( P_{Y|X}(\cdot|X) \parallel \hat{P}(\cdot|X) \right) \right]}_{\text{Kullback Leibler}} = \underbrace{\mathbb{E} \left[ -\log \hat{P}(Y|X) \right]}_{\text{Cross-entropy}} - \underbrace{H(Y|X)}_{\text{Entropía condicional}}$$

# Divergencia de Kullback Leibler

## Propuesta inicial

Busco  $\hat{P}(y|x)$  que minimice:

$$\underbrace{\mathbb{E} \left[ KL \left( P_{Y|X}(\cdot|X) \parallel \hat{P}(\cdot|X) \right) \right]}_{\text{Kullback Leibler}} = \underbrace{\mathbb{E} \left[ -\log \hat{P}(Y|X) \right]}_{\text{Cross-entropy}} - \underbrace{H(Y|X)}_{\text{Entropía condicional}}$$

Optimalidad para  $\ell(x, y) = -\log \hat{P}(y|x)$

$$\mathbb{E} \left[ -\log \hat{P}(Y|X) \right] \geq H(Y|X)$$

son igualdad si y solo si  $\hat{P}(y|x) = P_{Y|X}(y|x)$  para todo  $(x, y)$ .

# Divergencia de Kullback Leibler

## Propuesta inicial

Busco  $\hat{P}(y|x)$  que minimice:

$$\underbrace{\mathbb{E} \left[ KL \left( P_{Y|X}(\cdot|X) \parallel \hat{P}(\cdot|X) \right) \right]}_{\text{Kullback Leibler}} = \underbrace{\mathbb{E} \left[ -\log \hat{P}(Y|X) \right]}_{\text{Cross-entropy}} - \underbrace{H(Y|X)}_{\text{Entropía condicional}}$$

Optimalidad para  $\ell(x, y) = -\log \hat{P}(y|x)$

$$\mathbb{E} \left[ -\log \hat{P}(Y|X) \right] \geq H(Y|X)$$

son igualdad si y solo si  $\hat{P}(y|x) = P_{Y|X}(y|x)$  para todo  $(x, y)$ .


## Mismatch de métricas

El mínimo de la cross entropy no tiene por que coincidir exactamente con el mínimo de la probabilidad de error. En general se mira la cross entropy para reducir el bias y la probabilidad de error para prevenir el overfitting.

# Regresión Logística Binaria

## Función Sigmoide


$$\sigma(z) = \frac{1}{1 + e^{-z}}$$



# Regresión Logística Binaria

## Función Sigmoide

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$



## Propuesta

$$\begin{aligned}\hat{P}(1|x) &= \sigma(w^T x + b) \\ \hat{P}(0|x) &= 1 - \sigma(w^T x + b)\end{aligned}$$

# Regresión Logística Binaria

## Riesgo empírico

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n \ell(X_i, Y_i) = \\ - \frac{1}{n} \sum_{i=1}^n Y_i \log \left( \sigma(w^T X_i + b) \right) + (1 - Y_i) \log \left( 1 - \sigma(w^T X_i + b) \right) \end{aligned}$$




# Regresión Logística Binaria

## Riesgo empírico

$$\frac{1}{n} \sum_{i=1}^n \ell(X_i, Y_i) =$$
$$- \frac{1}{n} \sum_{i=1}^n Y_i \log \left( \sigma(w^T X_i + b) \right) + (1 - Y_i) \log \left( 1 - \sigma(w^T X_i + b) \right)$$

## Elección del máximo

$$\hat{P}(1|x) \leq \hat{P}(0|x) \Leftrightarrow w^T x + b \leq 0$$



# Curvas ROC


## Agregar un umbral

Puedo darle más peso a una clase:

$$w^T x + b \leq t$$

$$\text{TPR} = \mathbb{P}(Y = \phi(X) | \text{Es positivo})$$

$$\text{FPR} = \mathbb{P}(Y \neq \phi(X) | \text{Es negativo})$$



## Equal Error Rate (EER)

El EER es el error para el cuál los errores tipo I y II coinciden

# Regresión Logística Categórica ( $k$ clases)

## Regresión logística clásica

$$\hat{P}(y|x) = \begin{cases} \frac{e^{w_y^T x + b_y}}{1 + \sum_{j=1}^{k-1} e^{w_j^T x + b_j}} & y \in \{1, \dots, k-1\} \\ \frac{1}{1 + \sum_{j=1}^{k-1} e^{w_j^T x + b_j}} & y = k \end{cases}$$

# Regresión Logística Categórica ( $k$ clases)

## Regresión logística clásica

$$\hat{P}(y|x) = \begin{cases} \frac{e^{w_y^T x + b_y}}{1 + \sum_{j=1}^{k-1} e^{w_j^T x + b_j}} & y \in \{1, \dots, k-1\} \\ \frac{1}{1 + \sum_{j=1}^{k-1} e^{w_j^T x + b_j}} & y = k \end{cases}$$

## Softmax

$$\hat{P}(y|x) = \frac{e^{w_y^T x + b_y}}{\sum_{j=1}^k e^{w_j^T x + b_j}}, \quad y \in \{1, \dots, k\}$$

# Regresión Logística Categórica ( $k$ clases)

## Regresión logística clásica

$$\hat{P}(y|x) = \begin{cases} \frac{e^{w_y^T x + b_y}}{1 + \sum_{j=1}^{k-1} e^{w_j^T x + b_j}} & y \in \{1, \dots, k-1\} \\ \frac{1}{1 + \sum_{j=1}^{k-1} e^{w_j^T x + b_j}} & y = k \end{cases}$$

## Softmax

$$\hat{P}(y|x) = \frac{e^{w_y^T x + b_y}}{\sum_{j=1}^k e^{w_j^T x + b_j}}, \quad y \in \{1, \dots, k\}$$

## Riesgo empírico


$$\frac{1}{n} \sum_{i=1}^n \ell(X_i, Y_i) = \frac{1}{n} \sum_{i=1}^n \left[ \log \left( \sum_{j=1}^k e^{w_j^T X_i + b_j} \right) - (w_{Y_i}^T X_i + b_{Y_i}) \right]$$

# Regresión Softmax


## Elección del máximo

$$\arg \max_y \hat{P}(y|x) = \arg \max_y w_y^T x + b_y$$

Se separa con hiperplanos!



# Confusion Matrix




# Calibración

**Si valido hiperparámetros con respecto a la probabilidad de error, ¿la salida siguen siendo probabilidades?**

Para cada par  $(x, y)$ , existe  $0 \leq \zeta \leq \log |\mathcal{Y}|$  tal que

$$-\log \hat{P}(y|x) = -(\mathbf{z}(x))_y + \log \left( \mathbf{1}^T e^{\mathbf{z}(x)} \right) = \max_{y' \in \mathcal{Y}} (\mathbf{z}(x))_{y'} - (\mathbf{z}(x))_y + \zeta$$

Esta concentración de probabilidades es buena para acercarme al clasificador bayesiano, pero puede descalibrar la interpretación probabilística de  $\mathbf{f}$ .



*Guo et al. 2017: "On Calibration of Modern Neural Networks".*



# Calibración en deep-learning

## Temperature Scaling

Se soluciona con la inclusión de un nuevo parámetro (o hiper)  $T > 0$ :

$$f(x) = \frac{e^{z(x)/T}}{\mathbf{1}^T e^{z(x)/T}}$$

Es importante mirar la cross-entropy en la etapa de validación!

Dataset	Model	Uncalibrated	Temp. Scaling
Birds	ResNet 50	0.9786	<b>0.8792</b>
Cars	ResNet 50	0.5488	0.5311
CIFAR-10	ResNet 110	0.3285	0.2102
CIFAR-10	ResNet 110 (SD)	0.2959	0.1718
CIFAR-10	Wide ResNet 32	0.3293	0.2283
CIFAR-10	DenseNet 40	0.2228	<b>0.1750</b>
CIFAR-10	LeNet 5	0.4688	0.459
CIFAR-100	ResNet 110	1.4978	<b>1.0442</b>
CIFAR-100	ResNet 110 (SD)	1.1157	<b>0.8613</b>
CIFAR-100	Wide ResNet 32	1.3434	<b>1.0565</b>
CIFAR-100	DenseNet 40	1.0134	0.9026
CIFAR-100	LeNet 5	1.6639	<b>1.6560</b>
ImageNet	DenseNet 161	0.9338	0.8885
ImageNet	ResNet 152	0.8961	<b>0.8657</b>
SVHN	ResNet 152 (SD)	0.0842	<b>0.0821</b>
20 News	DAN 3	0.7949	0.7387
Reuters	DAN 3	0.102	0.0994
SST Binary	TreeLSTM	0.3367	<b>0.2739</b>
SST Fine Grained	TreeLSTM	1.1475	1.1168

Guo et al. 2017: "On Calibration of Modern Neural Networks".

# Modelos Discriminativos y Generativos

## Clasificación de Algoritmos

- **Modelos Discriminativos:** Modelan la dist. condicional  $\hat{P}(y|x)$ .
- **Modelos Generativos:** Modelan la dist. conjunta  $\hat{P}(x, y)$ .

Los modelos generativos permiten generar datos sintéticos!

# Modelos Discriminativos y Generativos

## Clasificación de Algoritmos

- **Modelos Discriminativos:** Modelan la dist. condicional  $\hat{P}(y|x)$ .
- **Modelos Generativos:** Modelan la dist. conjunta  $\hat{P}(x, y)$ .

Los modelos generativos permiten generar datos sintéticos!

## Linear Discriminant Analysis (LDA)

$$Y \sim \text{Cat}(\{c_1, \dots, c_K\}), \quad X|Y = k \sim \mathcal{N}(\mu_k, \Sigma)$$



# Linear Discriminant Analysis

## Expresiones Matemáticas

$$\hat{p}(x) = \sum_{k=1}^K c_k \frac{e^{-\frac{1}{2}(x-\mu_k)^T \Sigma^{-1}(x-\mu_k)}}{(2\pi)^{d_x/2} |\Sigma|^{1/2}}$$
$$\hat{P}(y|x) = \frac{e^{\mu_y^T \Sigma^{-1} x - \frac{1}{2} \mu_y^T \Sigma^{-1} \mu_y + \log(c_y)}}{\sum_{k=1}^K e^{\mu_k^T \Sigma^{-1} x - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log(c_k)}}$$

## Relación con Regresión Logística


Si  $w_y = \Sigma^{-1} \mu_y$  y  $b_y = -\frac{1}{2} \mu_y^T \Sigma^{-1} \mu_y + \log(c_y)$ ,  $\hat{P}(y|x)$  es el softmax. LDA utiliza hipótesis más fuertes ya que no solo asume  $\hat{P}(y|x)$  softmax, sino también  $\hat{p}(x)$  mezcla de gaussianas.

# Regresión Softmax

## Elección del máximo

$$\arg \max_y \hat{P}(y|x) = \arg \max_y w_y^T x + b_y$$

Se separa con hiperplanos!



# Estimación Insegada de Parámetros

## Estimadores

$$\mathcal{D}_k = \{x_i : 1 \leq i \leq n \wedge y_i = k\}$$

$$c_k = \frac{|\mathcal{D}_k|}{n}$$

$$\mu_k = \frac{1}{|\mathcal{D}_k|} \sum_{x \in \mathcal{D}_k} x$$

$$\Sigma_k = \frac{1}{|\mathcal{D}_k| - 1} \sum_{x \in \mathcal{D}_k} (x - \mu_k)(x - \mu_k)^T$$

$$\Sigma = \frac{1}{n - K} \sum_{k=1}^K (|\mathcal{D}_k| - 1) \Sigma_k$$

# Quadratic Discriminant Analysis

## Quadratic Discriminant Analysis (QDA)

$$Y \sim \text{Cat}(\{c_1, \dots, c_K\}), \quad X|Y = k \sim \mathcal{N}(\mu_k, \Sigma_k)$$

# Quadratic Discriminant Analysis

## Quadratic Discriminant Analysis (QDA)

$$Y \sim \text{Cat}(\{c_1, \dots, c_K\}), \quad X|Y = k \sim \mathcal{N}(\mu_k, \Sigma_k)$$

## Expresiones Matemáticas

$$\hat{p}(x) = \sum_{k=1}^K c_k \frac{e^{-\frac{1}{2}(x-\mu_k)^T \Sigma_k^{-1}(x-\mu_k)}}{(2\pi)^{d_x/2} |\Sigma_k|^{1/2}}$$

$$\hat{P}(y|x) = \frac{e^{-\frac{1}{2}(x-\mu_y)^T \Sigma_y^{-1}(x-\mu_y) + \log(c_y) - \frac{\log |\Sigma_y|}{2}}}{\sum_{k=1}^K e^{-\frac{1}{2}(x-\mu_k)^T \Sigma_k^{-1}(x-\mu_k) + \log(c_k) - \frac{\log |\Sigma_k|}{2}}}$$



# Quadratic Discriminant Analysis

## Quadratic Discriminant Analysis (QDA)

$$Y \sim \text{Cat}(\{c_1, \dots, c_K\}), \quad X|Y = k \sim \mathcal{N}(\mu_k, \Sigma_k)$$

## Expresiones Matemáticas

$$\hat{p}(x) = \sum_{k=1}^K c_k \frac{e^{-\frac{1}{2}(x-\mu_k)^T \Sigma_k^{-1}(x-\mu_k)}}{(2\pi)^{d_x/2} |\Sigma_k|^{1/2}}$$

$$\hat{P}(y|x) = \frac{e^{-\frac{1}{2}(x-\mu_y)^T \Sigma_y^{-1}(x-\mu_y) + \log(c_y) - \frac{\log |\Sigma_y|}{2}}}{\sum_{k=1}^K e^{-\frac{1}{2}(x-\mu_k)^T \Sigma_k^{-1}(x-\mu_k) + \log(c_k) - \frac{\log |\Sigma_k|}{2}}}$$

## Elección del máximo

$$\arg \max_y -\frac{1}{2}(x - \mu_y)^T \Sigma_y^{-1}(x - \mu_y) + \log(c_y) - \frac{\log |\Sigma_y|}{2}$$

# Modelos Paramétricos y No Paramétricos

## Clasificación de Algoritmos

- **Modelos Paramétricos:** Asumen conocimiento parcial sobre la distribución, indexándola por parámetros.
- **Modelos No Paramétricos:** No se asume una estructura a priori para la distribución.


# Modelos Paramétricos y No Paramétricos

## Clasificación de Algoritmos

- **Modelos Paramétricos:** Asumen conocimiento parcial sobre la distribución, indexándola por parámetros.
- **Modelos No Paramétricos:** No se asume una estructura a priori para la distribución.

## Histograma

El histograma asume una densidad constante por regiones. En cada región asigna  $\hat{p}(x) = \frac{K}{n \cdot V}$  donde  $n$  es la cantidad de muestras totales,  $K$  la cantidad de muestras en dicha región y  $V$  el volumen de la región.



## K-Vecinos más cercanos (KNN)

### Adaptando el concepto a aprendizaje supervisado

Asumiendo que  $\hat{P}(y) = \frac{N_y}{n}$  con  $N_y$  el número de muestras de la clase  $y$ , y que (en cada región)  $\hat{p}(x|y) = \frac{K_y}{N_y \cdot V}$  con  $K_y$  la cantidad de muestras que caen en la región de la clase  $y$ , se obtiene:

$$\hat{P}(y|x) = \frac{\hat{p}(x|y)\hat{P}(y)}{\sum_{i=1}^K \hat{p}(x|i)\hat{P}(i)} = \frac{K_y}{K}$$

Es decir, la proporción de muestras de la clase  $y$  en la región.

# K-Vecinos más cercanos (KNN)

## Adaptando el concepto a aprendizaje supervisado

Asumiendo que  $\hat{P}(y) = \frac{N_y}{n}$  con  $N_y$  el número de muestras de la clase  $y$ , y que (en cada región)  $\hat{p}(x|y) = \frac{K_y}{N_y \cdot V}$  con  $K_y$  la cantidad de muestras que caen en la región de la clase  $y$ , se obtiene:


$$\hat{P}(y|x) = \frac{\hat{p}(x|y)\hat{P}(y)}{\sum_{i=1}^K \hat{p}(x|i)\hat{P}(i)} = \frac{K_y}{K}$$

Es decir, la proporción de muestras de la clase  $y$  en la región.


## K-Vecinos más cercanos

KNN fija el valor de vecinos  $K$  y en base a esto define las regiones. Por ejemplo, la región utilizada para computar un *feature*  $x$  es la región centrada en  $x$  que posee  $K$  muestras (las  $K$  más cercanas a  $x$ ).

# K-Vecinos más cercanos (KNN)



## K-Vecinos más cercanos (KNN)



### Elección del máximo

Notar que para quedarse con el máximo de  $\hat{P}(y|x)$  no hace falta computarla. Simplemente se clasifica según sus  $K$  vecinos más cercanos, por mayoría.

# Support Vector Machines

## Clases linealmente separables


Sea la clasificación binaria  $y \in \{-1, 1\}$  y  $z(x) = w^T \cdot x + b$  su frontera de decisión. Decimos que las clases son linealmente separables, si existen  $w$  y  $b$  tales que  $y \cdot z(x) > 0$  para todo  $(x, y) \in \mathcal{D}_n$  (set de entrenamiento). Llamamos  $f_i(w, b) = y_i z(x_i) > 0$  con  $1 \leq i \leq n$ .



# Support Vector Machines

## Clases linealmente separables

Sea la clasificación binaria  $y \in \{-1, 1\}$  y  $z(x) = w^T \cdot x + b$  su frontera de decisión. Decimos que las clases son linealmente separables, si existen  $w$  y  $b$  tales que  $y \cdot z(x) > 0$  para todo  $(x, y) \in \mathcal{D}_n$  (set de entrenamiento). Llamamos  $f_i(w, b) = y_i z(x_i) > 0$  con  $1 \leq i \leq n$ .



- $w$  es ortogonal a la frontera y por lo tanto  $w \parallel (x - x_*)$  con  $x_*$  la proyección ortogonal de  $x$  sobre la frontera.

$$|w^T(x - x_*)| = \|w\| \|x - x_*\|$$

- Dado que  $x_*$  está sobre la frontera,  $w^T(x - x_*) = z(x)$  y por lo tanto:

$$d(x) = \|x - x_*\| = \frac{|z(x)|}{\|w\|} = \frac{y \cdot z(x)}{\|w\|}$$

# Support Vector Machines

## Margen

Se define el margen unilateral como criterio de peor caso:

$$m(w, b) = \min_{1 \leq i \leq n} \frac{y_i(w^T \cdot x_i + b)}{\|w\|} = \frac{1}{\|w\|} \min_{1 \leq i \leq n} f_i(w, b) = \frac{f_k(w, b)}{\|w\|}$$

con  $k$  un índice óptimo (función de  $w$  y  $b$ ). Por lo tanto, el problema a resolver es maximizar el margen:  $\max_{w, b} m(w, b)$ .

# Support Vector Machines

## Margen

Se define el margen unilateral como criterio de peor caso:

$$m(w, b) = \min_{1 \leq i \leq n} \frac{y_i(w^T \cdot x_i + b)}{\|w\|} = \frac{1}{\|w\|} \min_{1 \leq i \leq n} f_i(w, b) = \frac{f_k(w, b)}{\|w\|}$$

con  $k$  un índice óptimo (función de  $w$  y  $b$ ). Por lo tanto, el problema a resolver es maximizar el margen:  $\max_{w, b} m(w, b)$ .

## Escala

Sea  $\alpha \neq 0$ , está claro la decisión  $z(x) \geq 0$  no se ve afectada si reescalamos los parámetros  $w \leftarrow \alpha w$  y  $b \leftarrow \alpha b$ . Esto mismo ocurre con el margen  $m(\alpha w, \alpha b) = m(w, b)$ . Con lo cual no se pierde generalidad al asumir  $f_k(w, b) = 1$ . Luego  $m(w, b) = \frac{1}{\|w\|}$  y  $f_i(w, b) \geq 1$  para todo  $1 \leq i \leq n$ .

Las muestras en las que  $f_i(w, b) = 1$  se denominan vectores soporte.

# Support Vector Machines

## Problema de optimización

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i(w^T x_i + b) \geq 1 \quad (\forall 1 \leq i \leq n)$$

# Support Vector Machines


## Problema de optimización

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i(w^T x_i + b) \geq 1 \quad (\forall 1 \leq i \leq n)$$

## Relajando los márgenes

Dado que SVM es un algoritmo de peor caso es muy sensible a outliers. Eso hace que muchas veces sea conveniente permitir excepciones a los márgenes. Para ellos se definen las *slack variables*:

$$\xi_i = \begin{cases} 0 & \text{Si } y_i z(x_i) \geq 1 \\ |y_i - z(x_i)| & \text{Si } y_i z(x_i) < 1 \end{cases}$$



La nueva restricción es:

$$y_i z(x_i) \geq 1 - \xi_i$$

# Support Vector Machines

## Problema de optimización relajando el margen

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad \text{s.t.} \quad \begin{cases} y_i(w^T x_i + b) \geq 1 - \xi_i \\ \xi_i \geq 0 \end{cases} \quad (\forall 1 \leq i \leq n)$$

## Generalización a fronteras no lineales

Este método es fácilmente generalizable a diferentes familias de fronteras  $z(x) = w^T \phi(x) + b$ , donde la transformación  $\phi(\cdot)$  se denomina Kernell.

# Árboles de decisión

FALTA

# Bosques aleatorios

FALTA